

AI 协作摘要：从开放赛题到可审计城市科学研究

项目：Damage Is Not Need 队名：Auto-City-Research 代码：github.com/lreliya/auto-city-research

数据：huggingface.co/datasets/lreliya/auto-city-research

本文件是评审友好摘要。逐步输入、AI 输出摘要、人工决策、验证结果和证据链接保存在 logs/ai_collaboration_log.md；研究过程和命令分别保存在 logs/research_log.md 与 logs/command_log.md；每个主要结论通过 records/evidence_index.csv 关联到代码、配置、数据和图表。

1. 人机分工原则

原则	AI 的职责	人的职责
研究判断不外包	提出候选问题、反例和检验路径	确认研究问题、证据门槛与结论边界
执行过程可追溯	编写脚本、运行检查、组织日志和证据索引	审阅关键配置、接受或拒绝建议
负结果不得隐藏	主动检查相反证据、失败请求和不一致指标	决定按原样报告并收缩主张
结论服从证据	做数值、术语、图表、引用和包级审计	对最终提交内容负责

AI 不是结果署名者，也没有独立决定任何城市资源分配规则。项目中的权重只是透明政策情景，最终产物是供人类复核的优先级分歧审计。

2. 协作过程

阶段	AI 贡献	人工决策	验证证据
赛题核实	阅读 Competition 2 官网，提取允许的数据、评价标准和三类提交物	选择城市科学多源研究路线	submission/OFFICIAL_REQUIREMENT_MAP.md
问题凝练	将“使用 xView2”转化为“损毁排序是否足以代表城市恢复优先级”	冻结题目为 Damage Is Not Need	records/research_problem_and_datasets_20260710-2304.md
数据设计	建议 xBD、WorldPop、OSM、SVI、NFIP、FEMA assistance 与 Census 空间支持	接受多源证据分歧审计，不把任何代理当真值	configs/datasets.yaml
环境与数据盘点	建立 city 环境检查、只读盘点 xBD、修复 PROJ 数据路径	确认本阶段仅使用 CPU	scripts/verify_city_environment.py
基础分析	实现建筑解析、网格聚合、人口/OSM 融合和情景排序	锁定四个事件与透明权重情景	src/01 至 src/07
稳健性加固	实现四种损毁基线、两组各 10,000 次权重抽样和三种独立空间尺度	固定阈值，不根据结果降低门槛	src/18_run_baseline_weight_robustness.py; src/19_run_multiscale_robustness.py
人口分辨率审计	获取 100 m WorldPop，重算四事件并与 1 km 比较	将质量通过的 100 m 结果升级为主分析，保留 1 km 对照	src/26_audit_population_resolution.py
时间一致性检查	用 ohsome API 构造灾前 OSM 道路、设施和建筑快照	规定请求失败不可记为零，覆盖不足记为无法判定	src/22_run_historical_osm_sensitivity.py
外部代理检验	实现 NFIP、CDC SVI 和 FEMA Individual Assistance 的聚合、相关性和 bootstrap	接受代理之间的混合与负向结果	src/20_validate_harvey_nfip.py; src/23_validate_svi_ihp.py
最终共识审计	将定义、权重、人口分辨率、空间尺度和历史 OSM 标志统一到单元格证据表	冻结 3/4 基线、0.80 概率、双分辨率、双尺度门槛	src/24_build_final_consensus.py
图表与写作	生成 12 张出版级图，起草英文论文和中文报告并做一致性检查	采用“审计而非预测真值”的最终叙事	reports/; records/final terminology_ledger.md
公开复现与交付	构建固定版本下载、哈希校验、一键重算、PDF 和包级审计工具	只在真实验证后标记 release、CI、上传和回执完成	scripts/reproduce_core.py; src/12_run_final_submission_audit.py

3. 关键人类决策

决策一：研究对象不是“哪里损毁最重”，而是“不同证据为何给出不同优先级”

AI 最初可以直接围绕 xBD 损毁识别组织项目。人工判断认为，这不足以体现城市科学贡献，于是把损毁作为比较基线，加入人口、道路、设施和城市形态，研究不同证据之间的分歧。

决策二：100 m WorldPop 作为主分析，但必须保留 1 km 对照

100 m 数据覆盖四个事件且质量检查通过。人工接受其作为主要人口层，同时保留 1 km 结果，因为两种产品的事件总量、单元格排序和 Top-20% 集合存在实质差异。论文因此不把人口暴露当作无误差观测。

决策三：历史 OSM 证据单独判定，不用于制造候选

AI 发现当前 OSM 快照存在灾后编辑风险。人工要求加入灾前快照，并在看到设施覆盖不足后固定覆盖率门槛：不足时标记 not_assessable，而不是补零或放宽阈值。

决策四：外部代理不选“最好看的一个”

NFIP、SVI 与 FEMA assistance 测量不同维度，结果并不一致。人工拒绝把单个 NDCG 改善包装成“验证成功”，要求同时呈现相关性、排序质量、置信区间、覆盖范围和样本量。

决策五：最终四个单元格不是“真实高需求区”

四个 Mexico 单元格通过了固定的非时间稳健性门槛，但其历史 OSM 排名持续性不受支持。人工将结论限定为“跨设定稳健的优先级分歧”，并明确不能称为已验证需求。

4. AI 建议被修改或拒绝的实例

AI 建议或初版做法	人工处理	原因
用单一复合分数讲完整故事	修改为三个透明情景和大规模权重抽样	单一权重包含不可回避的政策判断
仅报告分位数 Top-20%	增加严格 exact Top-k	低损毁事件的大量并列会扩张集合
使用当前 OSM 并只写局限	增加历史 ohsome 检验	时间错位可能改变道路和设施证据
将 NFIP 的局部 NDCG 改善视为支持	拒绝	相关性下降且置信区间混合，NFIP 也不是真实需求
把通过非时间门槛的候选称为高需求地区	拒绝	没有真实未满足需求标签，且历史 OSM 不支持其持续性
在公开发布前写“CI 与全新 clone 已通过”	拒绝提前声明	每个交付状态必须有可核验记录

5. 失败、异常与修正记录

问题	处理方式	对结论的影响
初版人口层只有 1 km	下载并重算 100 m，建立分辨率审计	100 m 成为主分析；1 km 变为稳健性对照
OSM 历史设施覆盖不足	固定覆盖门槛，Harvey 标记无法判定	不把缺失当作“没有设施”
Mexico 损毁值大量并列	同时报分位数与 exact Top-k，并加入四基线共识	最终候选必须通过更严格定义检查
外部代理结果互相矛盾	原样展示全部代理及置信区间	主张收缩为多源证据分歧审计
图 10 标签映射产生空行	修正标签映射，重跑并逐图检查	防止视觉产物与数值表不一致
灰度导出在部分查看器异常	灰度图转回 RGB 容器后重新导出	保留灰度可读性并提高兼容性

6. 最终证据结果

- 100 m 主分析：73 个分位数情景共识分歧，115 个严格 Top-20% 分歧。
- 固定最终门槛：只保留 4 个 Mexico 单元格。
- 历史 OSM：这 4 个单元格均无持续性支持；时间支持候选数为 0。
- Harvey 外部代理：149 个 SVI/NFIP tracts、10,134 条聚合前 NFIP claims、41 个 FEMA assistance ZIP aggregates；指标结果混合。

- 因此最终论文不声称多源情景获得了真实需求，只证明损毁排序与其他城市证据之间存在可量化、可审计且对部分设定稳健的分歧。

7. 可审计性

每个主要结论至少关联以下要素：

- 固定配置；
- 执行脚本；
- 输入或派生数据；
- 数值输出和图表；
- 命令记录；
- 人机决策记录；
- 已知局限。

上述关联集中列在 `records/evidence_index.csv`。历史日志保留早期术语和失败路线，以证明过程没有在最终结果出现后被倒写；最终公开术语由 `records/final_terminology_ledger.md` 约束。

8. 有效性边界

- AI 生成的代码和文字均经过运行、数值核对或人工审阅，但这不等于消除所有软件错误。
- 公开复现可重算固定派生数据上的核心证据；完整源数据重建仍依赖外部数据提供方和网络端点。
- 没有真实未满足需求标签，因此不能以预测准确率解释本项目。
- 最终提交和公开发布状态只以清洁 clone、公开 CI、包级审计和上传回执为准，不以本摘要中的计划性文字代替。